

# Домашнее задание Phylogeny

Выполнил: Горяйнов Кирилл  
Группа: Б06-305

14 мая 2026 г.

# Содержание

|          |                                                                      |          |
|----------|----------------------------------------------------------------------|----------|
| <b>1</b> | <b>Подготовка данных</b>                                             | <b>3</b> |
| <b>2</b> | <b>Множественное выравнивание</b>                                    | <b>3</b> |
| <b>3</b> | <b>Построение филогенетических деревьев и обсуждение результатов</b> | <b>3</b> |

## 1 Подготовка данных

В качестве гена интереса был выбран ген *rbcl* для резуховидки Таля. Это ген, который кодирует большую субъединицу RuBisCo, потому все ортологи для него ищались среди таксона Viridiplantae - высших растений, выбрано 60 последовательностей, которые прикрепляются к отчету. Однако перед тем как переходить к обработке самих последовательностей нужно переписать заголовки fasta-файлов. Для этого был использован следующий скрипт:

```
input_file = "seq.fasta"
output_file = "renamed_seq.fasta"

with open(input_file, 'r') as infile, open(output_file, 'w') as outfile:
    for line in infile:
        if line.startswith('>'):
            match = re.search(r'organism=([\w\s]+?)\|', line)
            if match:
                species = match.group(1).replace(' ', '_')
                prot_id = line[line.find(' ') + 1:]
                new_header = f">{species}_{prot_id}\n"
                outfile.write(new_header)
            else:
                new_header = ">" + line[1:].strip().split()[0] + "\n"
                outfile.write(new_header)
            else:
                outfile.write(line)
```


## 2 Множественное выравнивание

На полученных последовательностях прямо в MEGA было произведено MSA — расстановка гомологичных позиций друг под другом, то есть множественное выравнивание с помощью алгоритма MUSCLE. Полученное выравнивание также прикрепляется.


## 3 Построение филогенетических деревьев и обсуждение результатов


Полученное выравнивание снова загружается в MEGA. Для начала найдем лучшую модель смотря на колонку BIC (Bayesian Information Criterion). Число ниже — модель лучше. В нашем случае лучше всего себя показала модель WAG+G+I, в дальнейшем будем использовать именно ее.

После проведенного анализа можно строить деревья. При построении для всех методов в пункте Test of Phylogeny выбирается Bootstrap, выставляется значение 100. Substitution Type: Amino acid, Gaps/Missing Data: Partial deletion (95%). Последний параметр выставляем дополнительно, он нужен так как слишком строгое удаление выкинет колонки с малым количеством пропусков. Для ML - поставим в пункте модели ту, которая показала лучшие результаты в анализе (WAG+G+I). Чтобы выставить именно эту модель в параметрах Rates among Sites - ставим +G (Gamma Distributed) и +I (Invariant sites). После этого непосредственно строим дерево.



После этого построим также два других дерева с помощью методов NJ и UPGMA со стандартными для всех моделей параметрами, указанными выше. в качестве модели оставим Jones-Taylor-Thornton (JTT).





Для того чтобы проанализировать полученные деревья можно по показателям bootstrap - это процент реплик, в которых этот узел собрался. ML дерево почти всегда дает самые высокие bootstrap при использовании модели с наименьшими показателями Байесовского информационного критерия. UPGMA дает низкие bootstrap, особенно в основании дерева (корень может оказаться случайным). NJ также дает неточные результаты, потому не является даже примерно таким статистически стабильным, как дерево ML.

Для сравнения биологичности полученных результатов следует интерпретировать нечитабельные индексы видов, полученные в дереве. Для этого можно взять участок дерева и сопоставить обозначения видов в дереве с их видовыми названиями. Для этого была использована база NCBI, затем проведен поиск систематического положения через Plantarium, а затем использованы данные статьи Theodor C. H. Cole, Vladimir Nikolaevich Godin (2024) по систематике семейства BRASSICACEAE, так как все рассмотренные объекты относятся именно к нему. Отдельно к отчету прикрепляется филогенетическое древо по систематике Крестоцветных как референс.

1. YP001123558.1 = *Draba nemorosa* (Крупка дубравная) (род *Draba*)
2. YP009891517.1 = *Alliaria petiolata* (Чесночница черешчатая) (род *Alliaria*)
3. YP009895413.1 = *Descurainia sophia* (Дескурайния Софии) (род *Descurainia*)
4. YP001123381.1 = *Capsella bursa-pastoris* (Пастушья сумка обыкновенная) (род *Capsella*)
5. YP009932931.1 = *Solms-laubachia himalayensis* (Сольмс-лаубахия гималайская.) (род *Oreoblastus*)
6. YP010895694.1 = *Chorispora sibirica* (Хориспора сибирская) (род *Chorispora*)
7. YP009898930.1 = *Macropodium nivale* (Долгоног снеговой) (род *Macropodium*)
8. QOJ51916.1 = *Lepidium apetalum* (Клоповник безлепестный) (род *Lepidium*)
9. YP001123470.1 = *Crucihimalaya wallichii* (Резуха бухарская) (род *Crucihimalaya*)

При сопоставлении данных из статьи о современной систематике Крестоцветных и результатов нескольких построенных разными методами деревьев можно понять, что дерево, построенное методом ML имеет наиболее близкие к актуальной на 2024 год систематической картине. Топология получается наиболее биологичной.

В реализованном пайплайне можно дополнительно добавить аутгруппу. Это позволит явно определить корень дерева, от которого будет проще строить всю остальную конструкцию. Для аутгруппы можно использовать очень эволюционно далекий вид, который филогенетически имеет крайне малое родство с использованными объектами. В качестве примера конкретно для группы высших растений аутгруппой может служить фотосинтезирующая водоросль, у которой также имеется рассматриваемый белок.

Можно также увеличить bootstrap до 500 или даже до 1000, потому как в таком случае деревья приобретут большую статистическую устойчивость, однако время построениякратно возрастет.

Использование конкатенации в виде анализа по нескольким последовательностям ортологов для построения видового дерева. Это исключит предвзятость по одному гену, уменьшит вероятность случайной ошибки.

После выравнивания мы никак не обрабатывали последовательность, мне кажется в еальной исследовательской задаче также стоило бы провести тримминг плохо выравненных участков, что повысило бы точность и статистическую устойчивость.